

REVISION SISTEMATICA METODOLOGIA PRISMA

Pregunta de Investigacion:

¿Cuál es la eficacia de los modelos de Deep Learning en la detección de intrusiones en redes IoT?

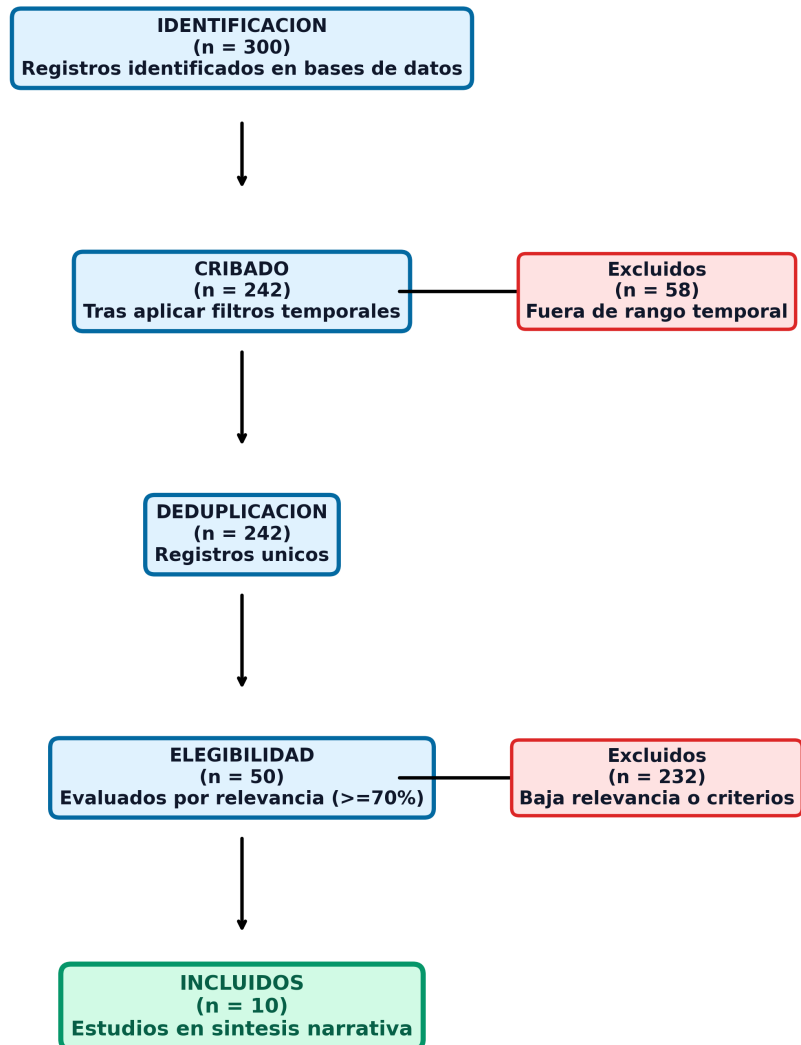
10 Estudios Incluidos

Universidad Privada Antenor Orrego

Asistente de Revision Sistemática con IA

1. Diagrama de Flujo PRISMA

DIAGRAMA DE FLUJO PRISMA



2. Síntesis Narrativa

Síntesis Narrativa

1. Introducción

La creciente adopción del Internet de las Cosas (IoT) ha traído consigo un aumento en las vulnerabilidades de seguridad, lo que ha llevado a la necesidad de desarrollar sistemas de detección de intrusiones (IDS) más eficientes. Esta revisión sistemática examina la eficacia de los modelos de Deep Learning (DL) en la detección de intrusiones en redes IoT, basándose en diez estudios recientes. Los hallazgos indican que, aunque los modelos de DL muestran un rendimiento superior en comparación con los enfoques tradicionales, existen desafíos significativos en términos de datos, interpretabilidad y adaptabilidad a diferentes entornos de IoT.

2. Eficacia de Algoritmos

Los estudios revisados presentan una variedad de enfoques de DL, destacando su eficacia en la detección de intrusiones. Por ejemplo, Wali et al. (2023) reportaron una precisión del 99% en la detección de ataques en redes de flujo, mientras que Narayana et al. (2024) lograron una precisión de hasta el 99.98% utilizando un modelo Bi-LSTM modificado. En contraste, Mahadevappa et al. (2021) encontraron que el Multi-Layer Perception (MLP) alcanzó solo un 79% de precisión, lo que sugiere que no todos los algoritmos de ML son igualmente efectivos en entornos de IoT. Además, el uso de técnicas avanzadas como el Transfer Learning (Eva et al., 2022) y el uso de redes neuronales complejas (Engy et al., 2024) también demostraron ser efectivos, alcanzando precisiones superiores al 97%.

3. Limitaciones Metodológicas

A pesar de los resultados prometedores, varios estudios identifican limitaciones metodológicas. Por ejemplo, la dependencia de conjuntos de datos equilibrados y etiquetados es un desafío común. Eva et al. (2022) señalaron que la escasez de datos etiquetados limita la eficacia de los modelos de DL en la detección de ataques de día cero. Además, la falta de interpretabilidad de los modelos de DL fue un tema recurrente, con Demostenes et al. (2023) enfatizando la necesidad de mecanismos de selección de características explicables para mejorar la confianza en los sistemas de detección. Asimismo, el alto índice de falsos positivos, como se menciona en el trabajo de Jamshidi et al. (2025), sigue siendo un obstáculo crítico para la implementación práctica de estos sistemas.

4. Metodologías Empleadas

Los estudios revisados emplean diversas metodologías, desde redes neuronales convolucionales (CNN) hasta arquitecturas de redes neuronales recurrentes (RNN). La mayoría de los estudios utilizaron conjuntos de datos específicos de IoT, como ToN-IoT y CICIDS, para evaluar el rendimiento de sus modelos. Sin embargo, la calidad de la evidencia varía, ya que algunos estudios, como el de Mahadevappa et al. (2021), se basaron en conjuntos de datos más antiguos como NSL-KDD, lo que puede no reflejar adecuadamente las amenazas actuales en entornos de IoT. Además, la comparación entre modelos a menudo carece de estandarización en las métricas de evaluación, lo que dificulta la generalización de los resultados.

5. Limitaciones y Gaps

Los estudios identifican varias limitaciones y áreas no exploradas. La escasez de datos etiquetados y equilibrados es un problema crítico que limita la capacidad de los modelos de DL para generalizar en entornos del mundo real (Eva et al., 2022). Además, la mayoría de los estudios se centran en la detección de intrusiones, pero no abordan adecuadamente la

respuesta a incidentes o la adaptación dinámica a nuevas amenazas (Jamshidi et al., 2025). También se observa una falta de investigación sobre la implementación de estos modelos en dispositivos IoT con recursos limitados, lo que podría restringir su aplicabilidad en escenarios reales.

6. Conclusiones

En conclusión, los modelos de Deep Learning muestran un potencial significativo para mejorar la detección de intrusiones en redes IoT, con tasas de precisión que superan el 99% en varios estudios. Sin embargo, las limitaciones en la disponibilidad de datos, la interpretabilidad de los modelos y la adaptabilidad a diferentes entornos de IoT representan desafíos que deben abordarse para lograr una implementación efectiva y confiable. La investigación futura debería centrarse en la creación de conjuntos de datos más robustos, el desarrollo de modelos interpretables y la exploración de estrategias de respuesta a incidentes para fortalecer la seguridad en el ecosistema IoT.

Referencias Bibliográficas

1. Jamshidi, S., Nikanjam, A., Wazed, N.K., & Khomh, F. (2025). Leveraging Machine Learning Techniques in Intrusion Detection Systems for Internet of Things. arXiv Preprint. <https://arxiv.org/pdf/2504.07220v1>
2. Wali, K.N., S, A.M., A, K.M., Sultan, A., Naghmeh, M., Abdulwahab, A., Safi, U., Naila, N., & Jawad, A. (2023). A hybrid deep learning-based intrusion detection system for IoT networks. Mathematical biosciences and engineering : MBE, 20(8), 13491-13520. <https://doi.org/10.3934/mbe.2023602>
3. Eva, R., Pol, V., Beatriz, O., Jos, C.J., Javier, V., Alejandro, P.M., & Ramon, C. (2022). Transfer-Learning-Based Intrusion Detection Framework in IoT Networks. Sensors (Basel, Switzerland), 22(15). <https://doi.org/10.3390/s22155621>
4. Mahadevappa, P., Muzammal, S.M., & Murugesan, R.K. (2021). A Comparative Analysis of Machine Learning Algorithms for Intrusion Detection in Edge-Enabled IoT Networks. arXiv Preprint. <https://arxiv.org/pdf/2111.01383v1>
5. Mousa, A. & Sung-Chul, H. (2023). An Adaptive Intrusion Detection System in the Internet of Medical Things Using Fuzzy-Based Learning. Sensors (Basel, Switzerland), 23(22). <https://doi.org/10.3390/s23229247>
6. Narayana, C.S.S., Prakash, S.S., Jaroslav, F., Parameshachari, B.D., Lakshmi, S.V., & Przemyslaw, F. (2024). OOA-modified Bi-LSTM network: An effective intrusion detection framework for IoT systems. Heliyon, 10(8), e29410. <https://doi.org/10.1016/j.heliyon.2024.e29410>
7. Engy, E., M, E.W., Haitham, E., Maazen, A., I, I.M., & Farouk, E.G. (2024). Deep Complex Gated Recurrent Networks-Based IoT Network Intrusion Detection Systems. Sensors (Basel, Switzerland), 24(18). <https://doi.org/10.3390/s24185933>
8. Demostenes, Z.R., Ogobuchi, D.O., Sarah, M.S., Ekikere, U.U., & Henrique, K.J. (2023). Attentive transformer deep learning algorithm for intrusion detection on IoT systems using automatic Xplainable feature selection. PloS one, 18(10), e0286652. <https://doi.org/10.1371/journal.pone.0286652>
9. B, S.S.K., Prasanna, M., V, M., Prabhu, J., M, S.K., & Muhammad, A.S. (2022). Design and Analysis of Multilayered Neural Network-Based Intrusion Detection System in the Internet of Things Network. Computational intelligence and neuroscience, 2022, 9423395. <https://doi.org/10.1155/2022/9423395>
10. Khalid, A., A, S.A., T, S.F., & K, A.R. (2021). IoT Intrusion Detection Taxonomy, Reference Architecture, and Analyses. Sensors (Basel, Switzerland), 21(19). <https://doi.org/10.3390/s21196432>

3. Artículos Destacados

Artículo 1 (Relevancia: 94.2%)

Leveraging Machine Learning Techniques in Intrusion Detection Systems for Internet of Things

Saeid

Leveraging Machine Learning Techniques in Intrusion Detection Systems for Intern

Saeid Jamshidi, Amin Nikanjam et al. (2025)

arXiv Preprint

Relevancia: 94%

Artículo 2 (Relevancia: 94.0%)

A hybrid deep learning-based intrusion detection system for IoT networks.

Khan,

A hybrid deep learning-based intrusion detection system for IoT networks.

Khan, Noor Wali, Alshehri, Mohammed S et al. (2023)

Mathematical biosciences and engineering : MBE

Relevancia: 94%